

Estimation d'une matrice de covariance pour la gestion d'actifs

Paul Demey, Gaël Riboulet

22 juillet 2003

*Groupe de Recherche Opérationnelle
Crédit Lyonnais
Immeuble Centorial
18, rue du Quatre Septembre
75002 Paris*

Table des matières

Introduction	3
1 Présentation des méthodes d'estimation	5
1.1 Estimation de la covariance empirique	5
1.2 Recherche d'une matrice définie positive	6
1.3 Estimation factorielle	8
1.4 Estimation par maximum de vraisemblance	11
1.5 Estimation par <i>imputation</i>	12
1.6 Estimation par <i>shrinkage</i>	13
2 Comparaison de la performance de chaque méthode	15
2.1 Présentation de la méthodologie	15
2.2 Présentation des résultats	17
2.3 Impact d'une erreur d'estimation sur le portefeuille optimal	20
Conclusion	20
Annexes	22
A Données utilisées pour les simulations	22
B Graphiques de distribution de l'erreur quadratique	24

Introduction

La gestion de portefeuille a pour but de calibrer au mieux la composition d'un portefeuille sur un profil de rendement-risque recherché par un investisseur. Ce problème a fait l'objet de nombreux travaux théoriques ces dernières décennies qui ont permis de donner un cadre quantitatif relativement complet.

Cette théorie prend en entrée d'une part un modèle d'évolutions des actifs financiers, et d'autre part une description quantitative des préférences de l'investisseur via une fonction d'utilité. Le problème qui se pose consiste alors à rechercher le portefeuille qui en moyenne maximise l'utilité de l'investisseur. Les deux composantes de cette approche méritent une attention particulière.

Les préférences de l'investisseur sont supposées suivre une axiomatique qui se traduit sur la fonction d'utilité par des conditions de type croissance et concavité¹. Le point le plus sensible consiste alors à estimer l'aversion au risque de l'investisseur, celle-ci étant définie par le ratio pente sur courbure de la fonction d'utilité. Cette aversion au risque peut-être interprétée comme l'augmentation nécessaire de la rentabilité moyenne pour compenser une augmentation du risque. La littérature sur le sujet fait apparaître quelques grandes familles de fonctions d'utilité, parmi lesquelles nous citerons :

- Constant Absolute Risk Aversion (CARA) :

$$U_\lambda(x) = -\exp(-\lambda x), \lambda > 0$$

- Constant Relative Risk Aversion (CRRA) :

$$U_\lambda(x) = \frac{x^\lambda}{\lambda}, \lambda < 1$$

L'autre composante s'attache à la modélisation de l'aléa gouvernant l'évolutions des actifs. Dans un cadre statique (modèle mono-périodique), la littérature retient essentiellement des rendements gaussiens dont la loi est entièrement déterminée par ses 2 premiers moments (moyennes et covariances). Cette paramétrisation, même si elle peut sembler inadéquate pour certaines classes d'actifs, a le mérite de permettre de nombreux calculs qui rendent la théorie interprétable. En effet, pour N classes d'actifs, si on suppose connus le vecteur des rendements espérés μ ainsi que la matrice de covariance Σ , le programme d'allocation statique dans le cas d'une fonction d'utilité exponentielle peut se réécrire sous la forme d'un programme classique de moyenne-variance à la Markowitz (1959) :

$$\max_{\alpha \in \mathbb{R}^N} \alpha^\top \mu - \frac{\lambda}{2} \alpha^\top \Sigma \alpha$$

À ce programme, on peut rajouter une contrainte de budget qui interdit à l'investisseur de se financer par un actif sans risque. Celle-ci peut être formalisée de la manière suivante :

$$\alpha^\top e = 1$$

où e est un vecteur de $\mathbb{R}^N$ composé de 1. Ainsi, le portefeuille solution du programme précédent que nous noterons α_λ^* , s'obtient aisément comme combinaison linéaire du portefeuille de variance minimale

¹Pour des raisons techniques on rajoutera également des conditions dites d'Inada sur les limites de la dérivée en 0 et à l'infini

$x_{min} = \frac{\Sigma^{-1}e}{e^\top \Sigma^{-1}e}$ et du portefeuille contenant les anticipations $x_\mu = \frac{\Sigma^{-1}\mu}{e^\top \Sigma^{-1}\mu}$, la pondération dépendant de l'aversion au risque.

$$\alpha_\lambda^* = \frac{b}{\lambda}x_\mu + \left(1 - \frac{b}{\lambda}\right)x_{min}$$

avec $b = e^\top \Sigma^{-1}\mu$.

En faisant varier le coefficient d'aversion au risque, l'ensemble des portefeuilles optimaux représenté dans un plan variance-rendement forme une parabole appelée frontière efficiente.

Ces résultats classiques appellent les commentaires suivants.

- Même si les résultats précédents sont ici donnés dans un cadre relativement simple qui ne nécessite pas d'outils mathématiques trop sophistiqués, leur extension en temps continu a fait l'objet de nombreuses études (Samuelson (1969), Merton (1998)) qui confirment en partie les résultats précédents. La démonstration de ces résultats est toutefois plus complexe et fait par exemple appel à la programmation dynamique (Cox et Huang (1989) ou Karatzas (1989)).
- Ces résultats théoriques sont d'une grande utilité pour argumenter de manière quantitative des décisions d'investissement mais engendrent des problèmes pratiques pour le gérant de portefeuille. En effet, la résolution des programmes d'optimisation précédents conduit très souvent à des portefeuilles dont on peut légitimement douter de la pertinence. Ceci s'explique par l'extrême sensibilité des portefeuilles optimaux aux inputs du modèle. La littérature sur le sujet semble s'accorder sur le fait que les erreurs d'estimation sur les rendements espérés constituait une des sources principales d'instabilité des résultats précédents. Nous noterons également que, du fait de l'inversion de la matrice de covariance dans la résolution du programme d'optimisation, un estimateur de cette matrice à la limite d'être défini (et positif) peut conduire également à des portefeuilles pour le moins folkloriques.

Cette note s'attarde sur ce dernier point et parcourt un ensemble de méthodes d'estimation qui permettrait de stabiliser à moindre coût les outputs du programme d'optimisation.

En ce qui concerne le vecteur des rendements espérés, même s'il ne fera pas l'objet d'attentions particulières, nous rappelons que portefeuilles et anticipations entretiennent une relation duale dont on peut profiter pour calibrer l'espérance des rendements (Black et Litterman (1991) et Black et Litterman (1992)). L'analyse moyenne-variance est alors menée relativement à un portefeuille de référence (benchmark) fixé a priori (on pourra penser par exemple au portefeuille de marché ou à une allocation dite « stratégique » imposée par l'investisseur). Les anticipations du gérant de portefeuille peuvent être ainsi décomposées en deux parties, l'une dite « neutre » rendant le benchmark efficient, l'autre dite « informative » expliquant l'écart entre le portefeuille optimal et le benchmark (Gaussel (2001)). Cette approche mène à des allocations « tactiques » qui peuvent différer significativement du benchmark selon la cohérence entre le benchmark retenu et les rendements anticipés.

Nous traiterons donc ici de l'estimation de la matrice de covariance qui, du fait de sa complexité, a souvent été abordée dans la littérature. On peut distinguer trois types d'approches. La première, la plus traditionnelle, repose sur le calcul de la matrice de covariance empirique (qui peut également être vue comme l'estimateur du maximum de vraisemblance). La seconde, l'analyse factorielle, s'appuie sur la théorie de l'ACP (analyse en composantes principale) dans laquelle on suppose l'existence d'un certain nombre de facteurs explicatifs. Par exemple, Bouchaud et al. (1999) utilisent la théorie des matrices aléatoires pour déterminer les facteurs explicatifs. Enfin, la dernière, l'estimation par *shrinkage*, proposée par Ledoit et Wolf (2002) et approfondie par Bengtsson et Holst (2002), combine

les deux approches précédentes.

La difficulté d'estimation de la matrice de covariance vient du fait que le nombre d'observations T des rendements n'est pas toujours suffisamment grand par rapport au nombre de classes d'actifs N : la covariance empirique est un estimateur sans biais de la covariance, mais sa convergence est relativement lente. À la limite, cet estimateur n'est plus utilisable lorsque $T < N$ puisque la matrice de covariance empirique n'est plus définie positive.

A contrario, l'analyse factorielle donne un estimateur dont la convergence est plus rapide, mais qui est biaisé (i.e. l'espérance de cet estimateur n'est pas la covariance réelle).

Après avoir passé en revue les différentes méthodes d'estimation, nous les comparerons – au sens de critères cohérents avec l'optique de gestion d'actifs – afin d'en déduire la méthodologie « optimale ».

1 Présentation des méthodes d'estimation

1.1 Estimation de la covariance empirique

Nous nous concentrons maintenant sur l'estimation de la matrice de covariance lorsque les données contiennent des valeurs manquantes. Ce sera le cas, par exemple, dès que les historiques des rendements des classes d'actif ne sont pas connus sur les mêmes périodes.

Considérons donc une série temporelle multivariée $X = \{x_n(t), t \in [1, T], n \in [1, N]\}$. Soit Σ la *vraie* matrice de covariance de X . Nous cherchons dans cette partie un estimateur $\hat{\Sigma}$ de Σ .

Un estimateur naturel s'écrit

$$\hat{\Sigma}_{i,j} = \frac{1}{T-1} \sum_{t=1}^T (x_i(t) - \bar{x}_i) (x_j(t) - \bar{x}_j)$$

où $\bar{x}_i$ est l'estimateur de la moyenne des $x_i(t)$.

Les méthodes que nous présentons maintenant permettent de gérer la présence de valeurs manquantes.

Estimateur *listwise*

La méthode *listwise* consiste à supprimer de la base toutes les observations qui contiennent au moins une valeur manquante. On notera cependant que la perte d'information peut être très importante. Imaginons que l'on souhaite calculer la covariance sur des classes d'actifs ayant un historique de 10 ans. Si pour une classe on ne dispose que d'un an d'historique, alors l'estimation *listwise* ne se fera que sur un an.

Estimateur *modified listwise*

L'idée est de séparer l'estimation de la variance et l'estimation de la matrice de corrélation : les variances sont calculées à partir de tout l'historique disponible (classe d'actif par classe d'actif), et la matrice de corrélation est estimée de manière *listwise*.

Estimateur *pairwise*

Une autre méthode souvent utilisée en statistique est l'estimation *pairwise*. Dans ce cas, chaque paramètre de la matrice de covariance est estimé séparément avec le maximum d'information.

$$\hat{\Sigma}_{i,j} = \frac{1}{T(i,j) - 1} \sum_{t=1}^T \mathbf{1}(i,j,t) \cdot (x_i(t) - \bar{x}_{i|j}) (x_j(t) - \bar{x}_{j|i})$$

où $\mathbf{1}(i,j,t)$ est une indicatrice qui vaut 1 si $x_i(t)$ et $x_j(t)$ ne sont pas des valeurs manquantes. Le nombre de valeurs sur lesquelles sont faites l'estimation vaut $T(i,j) = \sum_{t=1}^T \mathbf{1}(i,j,t)$.

Enfin, on distinguera l'estimateur *complete pairwise* de l'estimateur *partial pairwise* pour lesquels les moyennes $\bar{x}_{i|j}$ sont calculées de manière différente. En méthode *partial*, tout l'historique disponible est utilisé :

$$\bar{x}_{i|j} = \frac{1}{T(i,i)} \sum_{t=1}^T \mathbf{1}(i,i,t) \cdot x_i(t)$$

alors que la méthode *complete pairwise* n'utilise que l'historique commun aux séries $x_i(t)$ et $x_j(t)$:

$$\bar{x}_{i|j} = \frac{1}{T(i,j)} \sum_{t=1}^T \mathbf{1}(i,j,t) \cdot x_i(t)$$

Estimateur *modified pairwise*

De la même manière que *modified listwise*, les variances sont calculées à partir de tout l'historique disponible (classe d'actif par classe d'actif), et la matrice de corrélation est estimée de manière *pairwise*.

1.2 Recherche d'une matrice définie positive

Le problème majeur de l'estimateur *pairwise*, même s'il a l'avantage d'utiliser toute l'information disponible, est que la matrice de covariance obtenue n'est pas forcément définie positive. Il existe des algorithmes qui permettent de trouver la matrice définie positive la plus proche (au sens d'un critère que l'on précisera) d'une matrice initiale. Ce sont ces algorithmes que nous détaillons ici.

Au sens de la norme de Frobenius

Higham (2002) résout ce problème en recherchant la matrice de corrélation $\hat{\Omega}$ la plus proche d'une matrice initiale $\hat{\Omega}$ au sens de la norme de Frobenius (la norme d'une matrice A est définie par $\|A\|_F^2 = \sum_i \sum_j a_{ij}^2$).

L'idée présentée dans l'article est de définir deux sous-espaces des matrices de $\mathbb{R}^{n \times n}$, S et U par :

$$S = \{Y = Y^\top \in \mathbb{R}^{n \times n} : Y \geq 0\}$$

et

$$U = \{Y = Y^\top \in \mathbb{R}^{n \times n} : y_{ii} = 1, i = 1 \dots n\}$$

Le sous-espace S est l'ensemble des matrices symétriques et positives de $\mathbb{R}^{n \times n}$, et U est l'ensemble des matrices symétriques dont la diagonale vaut 1. L'intersection de ces deux sous-espaces est exactement l'ensemble des matrices de corrélation. On cherche donc la matrice $\hat{\Omega}$, à l'intersection de ces deux sous-espaces, et la plus proche de $\hat{\Omega}$ au sens de la norme de Frobenius.

En notant $P_U(A)$ la projection d'une matrice A sur U et $P_S(A)$ sa projection sur S , Higham (2002) montre que $\hat{\Omega}$ est solution de l'algorithme itératif :

$$\begin{aligned}\hat{\Omega}_0 &= \hat{\Omega} \\ \hat{\Omega}_n &= P_U \left(P_S \left(\hat{\Omega}_{n-1} \right) \right)\end{aligned}$$

c'est-à-dire que :

$$\lim_{n \rightarrow \infty} \|\hat{\Omega}_n - \hat{\Omega}\|_F^2 = 0$$

La projection d'une matrice A sur le sous-espace U s'écrit :

$$P_U(A) = (p_{ij}), \quad \text{avec } p_{ij} = \begin{cases} a_{ij} & \text{si } i \neq j, \\ 1 & \text{sinon.} \end{cases}$$

Quant à la projection d'une matrice A sur le sous-espace S , elle nécessite d'écrire la décomposition de Schur $A = QDQ^\top$ où $D = \text{diag}(\lambda_i)$ est une matrice diagonale, et Q est une matrice orthogonale. La projection sur S s'écrit alors :

$$P_S(A) = Q \text{diag}(\max(\lambda_i, 0)) Q^\top$$

On en déduit donc la matrice recherchée par itérations successives, pour un niveau de tolérance donnée. Plus la tolérance est faible, plus le nombre d'itérations sera important.

L'algorithme *square root matrix*

Soit $\hat{\Sigma}$ une matrice symétrique (obtenue par exemple par l'algorithme *pairwise*). L'objectif est de trouver la matrice $\hat{\Sigma}$, définie positive, la plus « proche » de $\hat{\Sigma}$.

Cet algorithme consiste à utiliser la décomposition suivante :

$$\hat{\Sigma} = F^2$$

avec

$$F = F_1 + iF_2$$

où F_1 et F_2 sont deux matrices positives. On définit alors $\hat{\Sigma}$ par :

$$\hat{\Sigma} = F_1^2$$

La matrice $\hat{\Sigma}$ est donc positive, mais pas forcément définie (i.e. les valeurs propres peuvent être nulles). Pour construire une matrice $\hat{\Sigma}$ définie positive, la décomposition suivante est utilisée ($\hat{\Sigma}$ est diagonalisable en tant que matrice symétrique réelle) :

$$\hat{\Sigma} = \Lambda^{-1} \text{diag}(\lambda_1 \cdots \lambda_n \cdots \lambda_N) \cdot \Lambda$$

dans laquelle les valeurs propres nulles sont remplacées par ε (petit et arbitrairement fixé) : $\lambda'_n = \max(\lambda_n, \varepsilon)$:

$$\hat{\Sigma} = \Lambda^{-1} \text{diag}(\lambda'_1 \cdots \lambda'_n \cdots \lambda'_N) \cdot \Lambda$$

Remarque 1 (Une deuxième vision) *On peut montrer que cette décomposition est équivalente à remplacer les valeurs propres de $\hat{\Sigma}$ inférieures à ε (avec $\varepsilon > 0$) par ε .*

Remarque 2 (Application à l'allocation d'actifs) *Si on se fixe un vecteur α de composition d'un portefeuille d'actifs, le risque associé à ce portefeuille s'écrit*

$$\alpha^\top \hat{\Sigma} \alpha = \alpha^\top F_1^2 \alpha$$

et le risque associé à la matrice $\hat{\Sigma}$ s'écrit :

$$\alpha^\top \hat{\Sigma} \alpha = \alpha^\top F_1^2 \alpha - \alpha^\top F_2^2 \alpha$$

donc

$$\alpha^\top \hat{\Sigma} \alpha \leq \alpha^\top \hat{\Sigma} \alpha$$

On montre donc que la transformation en square root matrix majore le risque encouru sur un portefeuille d'actifs. Cette propriété permet donc de s'assurer que le risque d'un portefeuille n'est pas sous-estimé par cette méthodologie.

1.3 Estimation factorielle

Modèle à un facteur

Le modèle de Sharpe (1963) suppose qu'il existe un facteur de marché auquel tous les actifs sont corrélés. Le rendement des actifs x_{it} s'écrit :

$$x_{it} = m_i + l_i f_t + \varepsilon_{it}$$

où les résidus ε_{it} sont iid, indépendants du rendement f_t du facteur de marché. On peut supposer par ailleurs que $\text{Var}(f_t) = 1$. La matrice de covariance $\hat{\Sigma}$ implicite à ce modèle s'exprime en fonction de

la matrice diagonale Δ contenant l'estimation de la variance des résidus, et l'estimation du vecteur l des l_i :

$$\hat{\Sigma} = ll^\top + \Delta$$

Nous verrons plus loin comment déterminer le facteur f_t . Notons ici que, par simplicité, on pourra retenir comme facteur la moyenne des rendements des actifs :

$$f_t = \frac{1}{N} \sum_{i=1}^N x_{it}$$

On prendra soin tout de même de réduire le vecteur f .

Ce modèle n'est pas réaliste. En revanche, il a l'avantage de conduire à une matrice de variance-covariance, certes biaisée, mais dont la convergence est beaucoup plus rapide que les estimateurs classiques. Concrètement, pour une même quantité de données (i.e. longueur d'historique), l'erreur d'estimation de cette matrice sera plus faible.

À la limite, lorsque le nombre d'observations T est inférieur au nombre de classes d'actifs, la matrice obtenue sera définie positive, contrairement à ce qu'on avait observé concernant l'estimation empirique.

Nous verrons dans la partie 1.6 comment tirer partie de ces propriétés intéressantes.

Généralisation au modèle à K facteurs

Le modèle précédent peut paraître insatisfaisant dans la mesure où un seul facteur ne contient pas suffisamment d'information. Théoriquement, pour déterminer une matrice de covariance de dimension N , N facteurs sont nécessaire pour tenir compte de toute l'information disponible. Souvent, cependant, K ($K < N$) facteurs bien choisis permettent d'expliquer la quasi-totalité des variations des rendements.

Notons X la matrice $T \times N$ des historiques des rendements, M le vecteur $1 \times N$ des moyennes des rendements, F la matrice $T \times K$ d'historique des facteurs (de variance 1), L la matrice $K \times N$ des facteurs *loadings*, et enfin ε la matrice $T \times N$ des résidus. La régression

$$X = M + FL + \varepsilon$$

permet d'estimer les matrices M , L , et ε .

Dans ces conditions, un estimateur de la matrice de covariance s'écrit :

$$\hat{\Sigma} = L^\top L + \Delta$$

Nous n'avons pas abordé la problématique du calcul des facteurs : comment les déterminer ? combien faut-il en retenir ? Nous tentons de répondre à ces questions dans la partie suivante.

Détermination des facteurs

La détermination des facteurs explicatifs F est largement étudiée dans la littérature. L'Analyse en Composantes Principales (ACP) est un algorithme qui permet d'y parvenir.

Considérons la matrice de covariance estimée *listwise* $\hat{\Sigma}_{lw}$. Cette matrice est symétrique réelle, donc diagonalisable, et peut s'écrire :

$$\hat{\Sigma}_{lw} = U\Lambda U^\top$$

où $\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_N \end{pmatrix}$ est diagonale et $U = (u_1 \mid u_2 \mid \dots \mid u_N)$ est la matrice (orthogonale)

contenant les vecteurs propres de $\hat{\Sigma}_{lw}$. Si l'on exige que la diagonale de Λ soit ordonnée par valeurs décroissantes, i.e. $\lambda_1 \geq \lambda_2 \dots \geq \lambda_N$, la décomposition ci-dessus est unique, au signe près des colonnes de U .

Les facteurs f_i associés aux composantes principales u_i sont les colonnes de la matrice F déterminée par la relation :

$$F = XU\Lambda^{-\frac{1}{2}}$$

la multiplication par $\Lambda^{-\frac{1}{2}}$ permettant d'obtenir une matrice standardisée (de variance 1). Ces facteurs sont :

- non-corrélés entre eux, i.e. $\text{cov}(f_i, f_j) = 0$ si $i \neq j$
- de variance $\text{Var}(f_i) = 1$

La première composante f_1 (associée à la plus grande valeur propre λ_1) explique la plus grande part de la variance de X . Plus précisément, la part de variance expliquée par les k premiers facteurs vaut :

$$\frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_N}$$

Combien de facteurs faut-il retenir ?

Pour retenir le nombre optimal de facteurs, plusieurs méthodes sont proposées dans la littérature.

La première, la plus classique considère qu'on ne retient que les facteurs f_i associés aux valeurs propres λ_i qui expliquent au moins $\frac{1}{N} \times$ variance totale, i.e. tels que

$$\lambda_i \geq \frac{1}{N} (\lambda_1 + \dots + \lambda_N)$$

Ce seuil ne repose sur aucune justification mathématique mais provient plutôt de l'intuition selon laquelle « un vecteur propre significatif doit contenir plus d'information que la moyenne ».

Bouchaud et al. (1999) proposent une deuxième méthode qui repose sur la théorie des matrices aléatoires. Elle s'appuie sur un résultat classique qui donne la distribution des valeurs propres d'une matrice de covariance aléatoire.

Soit Σ une matrice de covariance calculée à partir d'un historique des rendements $X : \Sigma = \frac{1}{T} X^\top X$, où X est une matrice rectangulaire $T \times N$ aléatoire (les rendements x_{it} étant iid). La densité $\rho(\lambda)$ des valeurs propres de Σ est connue lorsque $N \rightarrow \infty$, $T \rightarrow \infty$, et $Q = T/N \geq 1$ et s'écrit

$$\begin{aligned}\rho(\lambda) &= \frac{Q}{2\pi\sigma^2} \frac{\sqrt{(\lambda_{max} - \lambda)(\lambda - \lambda_{min})}}{\lambda} \\ \lambda_{min}^{max} &= \sigma^2 \left(1 + 1/Q \pm \sqrt{1/Q}\right)\end{aligned}$$

où σ^2 est la variance des éléments de X .

Ce résultat est valable à distance infinie, mais nous l'appliquerons — de manière approximative — à distance finie. On peut en déduire notamment que la probabilité pour qu'une valeur propre soit supérieure à λ_{max} est nulle. Or, en calculant les valeurs propres à partir de données de marché, on constate justement l'inverse : la plus grande valeur propre λ_1 est supérieure à λ_{max} . Cela signifie tout simplement que l'hypothèse de pure « bruit » pour le rendements des actifs n'est pas cohérente. On remarquerait par ailleurs que le vecteur propre associé à cette plus grande valeur propre est généralement le « marché » lui-même, c'est-à-dire que, grosso-modo, chacun des actifs a un poids de $1/N$.

Dans ce contexte, Bouchaud et al. (1999) proposent une méthodologie itérative pour ne retenir que les vecteurs propres significatifs :

- extraire le vecteur propre correspondant à la plus grande valeur propre si celle-ci est supérieure à λ_{max} ;
 - recalculer la nouvelle densité de probabilité des valeurs propres (la variance σ^2 est recalculée en soustrayant la contribution de la plus grande valeur propre $\sigma^2 \leftarrow \sigma^2 - \frac{1}{N} \lambda_1$).
- L'algorithme est itéré jusqu'à ce qu'aucune valeur propre ne soit significative.

1.4 Estimation par maximum de vraisemblance

L'objectif de cette partie est de présenter l'estimateur $\hat{\Sigma}$ du maximum de vraisemblance de la matrice de covariance Σ . Les rendements sont supposés suivre une loi normale multivariée, de moyenne μ et de matrice de covariance Σ . Conditionnellement à μ et Σ , la densité de probabilité des rendements s'écrit

$$p(x_t | \Sigma, \mu) = \frac{1}{(2\pi)^{N/2} \det(\Sigma)^{1/2}} e^{-(x_t - \mu)^\top \Sigma^{-1} (x_t - \mu)}$$

La vraisemblance est égale au produit des probabilités conditionnelles :

$$\begin{aligned}V(\Sigma, \mu) &= \prod_{t=1}^T p(x_t | \Sigma, \mu) \\ &= \prod_{t=1}^T \frac{1}{(2\pi)^{N/2} \det(\Sigma)^{1/2}} e^{-(x_t - \mu)^\top \Sigma^{-1} (x_t - \mu)}\end{aligned}$$

où les x_t sont les réalisations de X . La log-vraisemblance vaut donc (à une constante près) :

$$LV(\Sigma, \mu) = \sum_{t=1}^T -\frac{1}{2} \ln(\det(\Sigma)) - \frac{1}{2} (x_t - \mu)^\top \Sigma^{-1} (x_t - \mu)$$

Avec un peu de calcul, on peut montrer (en écrivant les conditions du premier ordre) que $\hat{\mu}$ et $\hat{\Sigma}$ qui maximisent la log-vraisemblance sont respectivement la moyenne empirique et la covariance empirique :

$$\hat{\Sigma}_{i,j} = \frac{1}{T-1} \sum_{t=1}^T (x_i(t) - \bar{x}_i)(x_j(t) - \bar{x}_j)$$

On retrouve donc l'estimateur *listwise* décrit précédemment. Cependant, ce résultat n'est valable que lorsque X ne contient pas de valeurs manquantes.

Dans le cas où on observe des valeurs manquantes, il devient nécessaire de résoudre le problème de manière numérique. L'algorithme EM (Expectation Maximisation) de Dempster et al. (1977) est précisément conçu pour ce type de problème d'estimation, où le principe du maximum de vraisemblance pour les données complète X donnerait lieu à des calculs simples, mais où l'on observe en fait qu'une partie X_{obs} de ces données. On notera X_{miss} les données manquantes.

La procédure commence avec une valeur initiale des paramètres (espérance + matrice de covariance) θ_0 . Chaque itération consiste à calculer les nouveaux paramètres θ_{n+1} à partir de ceux de l'itération précédente θ_n de façon à maximiser une fonction $Q(\theta, \theta_n)$, ainsi définie :

$$Q(\theta, \theta_n) = \mathbb{E}_{X_{miss}}[\ln(P(X|\theta)) | \theta_n, X_{obs}]$$

et qui correspond à l'espérance de la log-vraisemblance complète, espérance prise sur la distribution a posteriori des données manquantes, connaissant les observations X_{obs} et basée sur les anciens paramètres θ_n

Chaque itération peut se décomposer en deux étapes :

1. L'étape E (*Expectation*) : calculer les composantes de $Q(\theta, \theta_n)$ qui ne dépendent pas de θ .
2. L'étape M (*Maximisation*) : mettre à jour les paramètres par

$$\theta_{n+1} = \arg \max_{\theta} Q(\theta, \theta_n)$$

L'algorithme converge vers le paramètre $\hat{\theta}$ qui maximise la log-vraisemblance

$$\hat{\theta} = \arg \max_{\theta} \ln(P(X|\theta))$$

1.5 Estimation par *imputation*

Le principe de l'estimation par *imputation* est de remplacer les valeurs manquantes par des valeurs « plausibles ». On distingue plusieurs type d'estimateurs, suivant la manière dont sont calculées les valeurs manquantes :

- *mean imputation* : les valeurs manquantes sont remplacées par la valeur moyenne des valeurs observables. Cette technique simple a l'inconvénient de sous-estimer la variance.
- *regression imputation* : les valeurs manquantes sont remplacées par les valeurs issues d'une régression linéaire sur les valeurs observables. Là encore, la variance est sous-estimée, mais moins que dans le cas précédent.
- *hot deck imputation* : les valeurs manquantes sont remplacées par une valeur prise dans un cas similaire, mais observable de la base de données. Il existe différentes méthodes permettant de préciser en quel sens deux cas sont « similaires ».

Par la suite, lorsqu'on parlera d'estimation par *imputation*, on fera référence implicitement à la méthode *mean imputation*.

1.6 Estimation par *shrinkage*

D'après les parties précédentes, on sait que l'estimateur empirique de la matrice de covariance est un estimateur non biaisé mais qui requiert un grand nombre d'observations pour converger vers la « vraie » matrice de covariance. De plus, cet estimateur possède des valeurs propres d'autant plus proches de zéro que le nombre de données est faible, ce qui pose des problèmes numériques lors de l'inversion de cette matrice. En d'autres termes, la structure de cette matrice est relativement instable.

A contrario, les estimateurs basés sur une analyse factorielle sont biaisés mais convergent beaucoup plus vite. De plus, de par leur construction, ces estimateurs sont à coup sûr définis et positifs, ce qui leur confère une structure assez stable et permet notamment une inversion sans souci.

Cette section se propose d'étudier des combinaisons linéaires entre l'estimateur empirique et l'estimateur que nous appellerons factoriel. Nous consacrons la première partie de cette section à une série d'arguments plus ou moins intuitifs justifiant un redressement de l'estimateur empirique de la matrice de covariance. Dans un second temps et après avoir présenté le principe du shrinkage, nous étudions l'estimateur proposé par Ledoit et Wolf (2002) basé sur une pondération optimale asymptotiquement.

Dans cette partie, nous noterons S l'estimateur empirique de la matrice de covariance et F l'estimateur basé sur une analyse factorielle.

Remarques Préliminaires

Nous apportons ici quelques éléments qui justifient le traitement qui sera présenté plus loin. Les résultats qui suivent sont essentiellement basés sur une comparaison des valeurs propres de S par rapport à celles de $\hat{\Sigma}$. Cette partie est inspirée de Ledoit et Wolf (2003).

Commençons par remarquer que, du fait que S est un estimateur sans biais de Σ , et pour tout μ

$$\mathbb{E}\|S - \mu Id\|^2 = \mathbb{E}\|S - \Sigma\|^2 + \mathbb{E}\|\Sigma - \mu Id\|^2$$

La norme de Frobenius peut être interprétée également au moyen des valeurs propres que nous noterons $\lambda_1, \dots, \lambda_N$ pour Σ et $l_1, \dots, l_N$ pour S . Après avoir posé $\mu = \mathbb{E}[\frac{1}{N} \sum_{i=1}^N l_i] = \frac{1}{N} \sum_{i=1}^N \lambda_i$, la relation précédente se réécrit alors

$$\mathbb{E}[\frac{1}{N} \sum_{i=1}^N (l_i - \mu)^2] = \frac{1}{N} \sum_{i=1}^N (\lambda_i - \mu)^2 + \mathbb{E}\|S - \Sigma\|^2$$

En d'autres termes, les valeurs propres de l'estimateur empirique sont plus dispersées autour de leur moyenne que celles de la vraie matrice de covariance, l'écart étant justement la variance de l'estimateur. Cet excès de dispersion implique que la plus grande valeur propre de S est en moyenne au dessus de la plus grande valeur propre de Σ et que la plus faible est en dessous. Ainsi peut-il sembler naturel de redresser S de telle sorte que les valeurs propres de S soient plus concentrées autour de leur moyenne.

Une manière de procéder est justement de corriger S en retenant un estimateur du type :

$$\widehat{\Sigma} = \alpha \mu Id + (1 - \alpha)S$$

Ceci est fait dans Ledoit et Wolf (2003), et le *alpha* optimal réduit la dispersion des valeurs propres de l'estimateur en dessous de la dispersion des valeurs propres de Σ . Ce résultat peut paraître assez surprenant, puisque, intuitivement on aurait pu attendre que les deux coïncident en moyenne.

Ce résultat s'explique par le fait que l'erreur commise sur l'estimation des valeurs propres de S se conjugue avec l'erreur d'estimation des vecteurs propres. En d'autres termes, les deux matrices S et Σ ne diagonalisent pas dans la même base. Or, la dispersion des termes diagonaux d'une matrice symétrique réelle est maximale lorsque cette matrice est diagonalisée. Ainsi, en notant $\gamma_1, \dots, \gamma_N$ les vecteurs propres de Σ et $g_1, \dots, g_N$ ceux de S , on a $l_i = g_i^\top S g_i$ qui peut être comparé (puisque S est sans biais) à $g_i^\top \Sigma g_i$. De même, la dispersion des l_i peut être comparée à celles des $g_i^\top \Sigma g_i$. D'après ce qu'on a dit plus haut, cette dispersion est plus faible que celles des $\lambda_i = \gamma_i^\top \Sigma \gamma_i$.

Finalement, on retiendra de cette partie que l'estimateur à retenir doit avoir des valeurs propres moins dispersées que celles de Σ .

Shrinkage Linéaire Optimal

Le problème que nous nous posons consiste à obtenir une combinaison linéaire de S et F la plus proche possible de la vraie matrice de covariance. La distance que nous retenons est la norme de Froebenius² et l'optimisation recherchée s'écrit :

$$\min_{\alpha \in \mathbb{R}} \mathbb{E} \left\| \underbrace{\alpha F + (1 - \alpha)S}_{\widehat{\Sigma}} - \Sigma \right\|^2$$

Ce programme peut être interprété comme la recherche d'un compromis entre biais et variance. En effet, la fonction objectif à minimiser peut se décomposer de la manière suivante :

$$\begin{aligned} \mathbb{E} \|\widehat{\Sigma} - \Sigma\|^2 &= \mathbb{E} \|\widehat{\Sigma} - \mathbb{E}[\widehat{\Sigma}]\|^2 + \mathbb{E} \|\mathbb{E}[\widehat{\Sigma}] - \Sigma\|^2 \\ &= \text{Variance} + \text{Biais} \end{aligned}$$

A partir de cette décomposition, on remarque que le cas $\alpha = 0$ correspond à ($\widehat{\Sigma} = S$) et on a que de la variance. De même, $\alpha = 1$, c'est-à-dire ($\widehat{\Sigma} = F$) correspond au cas où on a surtout du biais. Entre ces deux points se trouvent probablement un compromis que nous cherchons à estimer.

La pondération optimale est relativement simple à obtenir mais dépend de la vraie matrice de covariance (qui est bien sûr inobservable), elle s'exprime de la manière suivante :

$$\alpha^* = \frac{\mathbb{E} \|S - \Sigma\|^2 - \mathbb{E} \langle F - \mathbb{E}[F], S - \Sigma \rangle}{\mathbb{E} \|F - S\|^2}$$

Ainsi, même si ce résultat n'est pas exploitable en tant que tel, il nous renseigne de manière qualitative sur la manière de corriger l'estimateur empirique de la covariance. α^* (qui s'interprète comme le poids du modèle factoriel) qu'on appelle intensité du shrinkage est d'autant plus grand que la variance de S est grande que F est proche de S , et que la corrélation entre S et F est faible.

²Cette norme euclidienne est associée au produit scalaire $\langle X, Y \rangle = \text{Trace}(XY)$

Cette intensité s'interprète également comme un gain de l'opération, puisque le pourcentage d'erreur moyenne gagné par rapport à l'estimateur classique S est donné par :

$$\frac{\mathbb{E}\|S - \Sigma\|^2 - \mathbb{E}\|\alpha^* F + (1 - \alpha^*)S - \Sigma\|^2}{\mathbb{E}\|S - \Sigma\|^2} = \alpha^{*2}$$

Pratiquement, les résultats précédents ne sont pas exploitables puisque dépendant d'inobservables. C'est pourquoi, Ledoit et Wolf (2002) et Bengtsson et Holst (2002) proposent à partir d'un développement asymptotique de travailler avec l'expression suivante :

$$\alpha^* = \frac{1}{T} \frac{\pi - \rho}{\gamma} + O\left(\frac{1}{T^2}\right)$$

avec

- π est la variance asymptotique de S dont un estimateur consistant est donné par $\sum_{i,j} p_{ij}$ avec

$$p_{ij} = \frac{1}{T} \sum_{t=1}^T ((x_{it} - \bar{x}_i)(x_{jt} - \bar{x}_j) - S_{ij})^2$$

- γ est le biais du modèle à facteur, dont un estimateur consistant est donné par $\sum_{i,j} c_{ij}$ avec

$$c_{ij} = (F_{ij} - S_{ij})^2$$

- ρ est la covariance asymptotique de S et F dont un estimateur consistant est donné par $\sum_{i,j} r_{ij}$ avec $r_{ii} = p_{ii}$ et pour $i \neq j$

$$r_{ij} = \frac{1}{T} \sum_{t=1}^T \sum_{k=1}^K [u_{ijkt}(x_{it} - \bar{x}_i)(x_{jt} - \bar{x}_j)(f_{kt} - \bar{f}_k) - F_{ij}S_{ij}]^2$$

où f_k , $\bar{f}_k$, et K sont respectivement les facteurs, leurs moyennes et le nombre de facteur retenus pour calculer la matrice F , enfin u_{ijkt} est donné par

$$u_{ijkt} = (x_{it} - \bar{x}_i) \frac{\text{cov}(x_j, f_k)}{\sigma_{f_k}^2} + (x_{jt} - \bar{x}_j) \frac{\text{cov}(x_i, f_k)}{\sigma_{f_k}^2} + (f_{kt} - \bar{f}_k) \frac{\text{cov}(x_j, f_k) \text{cov}(x_i, f_k)}{\sigma_{f_k}^4}$$

2 Comparaison de la performance de chaque méthode

Jusqu'à présent, nous avons présenté différentes méthodes d'estimation possibles pour la matrice de covariance. Il est difficile de dire à ce stade laquelle doit être utilisée dans une optique d'allocation d'actifs. En effet, ces matrices résultent d'un critère du type « minimiser l'erreur quadratique » ou « maximiser la vraisemblance ». Ces critères avaient l'avantage de conduire à des matrices de covariance facilement calculables. Mais pour tester leur pertinence, nous nous orientons dorénavant vers des critères cohérents avec l'allocation d'actifs.

2.1 Présentation de la méthodologie

On se fixe N classes d'actifs dont les rendements suivent une loi normale multivariée. Le vecteur de rendement espéré est noté μ , et la matrice de covariance entre les rendements des actifs Σ . Notons que ces paramètres sont supposés connus.

Le principe que nous avons retenu consiste à simuler des historiques de rendement pour chaque classe d'actif, conformément à cette distribution. Selon les cas, on pourra remplacer certaines valeurs simulées par des valeurs manquantes, pour reproduire le cas où les historiques sont connus sur des historiques de longueurs différentes.

À partir de ces historiques, nous estimons une matrice de covariance $\hat{\Sigma}$ avec chacune des méthodes présentées dans la partie 1.

Pour apprécier la performance des méthodes d'estimation, nous utiliserons trois critères qui peuvent être vus comme une mesure de la distance entre Σ et $\hat{\Sigma}$:

- Une mesure quadratique égale à la somme des carrés des écarts des éléments des deux matrices :

$$d_1 = \|\hat{\Sigma} - \Sigma\|^2$$

- La *tracking error* entre deux portefeuilles α et $\hat{\alpha}$ (ce sont des vecteurs représentant les proportion de la richesse initiale investie dans les deux classes d'actifs). Les deux portefeuilles sont d'une part celui obtenu en supposant les paramètres μ et Σ connus, et d'autre part celui obtenu en utilisant les paramètres μ et $\hat{\Sigma}$. On notera que dans tous les cas, les rendements espérés sont connus, puisqu'on ne cherche à mesurer que l'impact d'une erreur d'estimation sur Σ .

Le portefeuille α est solution du programme P_1 :

$$P_1 : \begin{cases} \max_x & x^\top \mu - \lambda x^\top \Sigma x \\ \text{s.c.} & e^\top x = 1 \end{cases}$$

et le portefeuille $\hat{\alpha}$ est solution du programme P_2 :

$$P_2 : \begin{cases} \max_x & x^\top \mu - \lambda x^\top \hat{\Sigma} x \\ \text{s.c.} & e^\top x = 1 \end{cases}$$

La distance d_2 s'écrit alors :

$$d_2 = \sqrt{(\alpha - \hat{\alpha})^\top \Sigma (\alpha - \hat{\alpha})}$$

- Une distance notée d_3 qui correspond à la variance réelle d'un portefeuille (estimé avec $\hat{\Sigma}$) comme étant celui de variance minimale.

Le portefeuille qui minimise le risque, c'est-à-dire qui est solution du programme

$$\begin{cases} \min_x & x^\top \Sigma x \\ \text{s.c.} & e^\top x = 1 \end{cases}$$

vaut $\alpha = \frac{\Sigma^{-1}e}{e^\top \Sigma^{-1}e}$. De la même manière, le portefeuille estimé avec la matrice de covariance $\hat{\Sigma}$ vaut $\hat{\alpha} = \frac{\hat{\Sigma}^{-1}e}{e^\top \hat{\Sigma}^{-1}e}$.

Dans ce cadre, nous définirons la distance d_3 comme la différence entre le risque du portefeuille $\hat{\alpha}$ et le risque du portefeuille α :

$$d_3 = \hat{\alpha}^\top \Sigma \hat{\alpha} - \alpha^\top \Sigma \alpha$$

Pour chaque simulation des rendements historiques, on obtient une erreur par méthode d'estimation. En itérant la procédure, c'est-à-dire en effectuant un nombre N_s de simulations, on en déduit une distribution de l'erreur (au sens de la distance d_1 , de d_2 ou de d_3) par méthode d'estimation. La comparaison de ces distributions fera apparaître la méthode « optimale ».

2.2 Présentation des résultats


Il s'avère que les résultats diffèrent selon que les données comportent ou non des valeurs manquantes. Nous détaillons donc les résultats dans chacun de ces deux cas.

Les matrices μ et Σ sont détaillées en annexe A. Les autres paramètres sont les suivants :

- le coefficient d'aversion au risque vaut $\lambda = 3$;
- le nombre de simulations vaut $N_s = 10\,000$.

Données sans valeurs manquantes


Les treize classes d'actifs sont supposées avoir le même nombre d'observations historiques $T = 5 \times 12$ (i.e. cinq années d'observations mensuelles). Le graphique 1 représente la distribution de la distance d_2 pour chacune des méthodes. L'estimation par maximisation de la vraisemblance est notée « EM » (du nom de l'algorithme Expectation-Maximisation).



Graphique 1: Tracking error entre le portefeuille estimé et le portefeuille optimal

On remarque que les estimations *listwise*, *pairwise*, par maximum de vraisemblance et par *imputation* sont les mêmes méthodes dans le cas où il n'y a pas de données manquantes. Les méthodes d'estimation factorielles engendrent une perte d'information, qui se traduit par des *tracking error* qui peuvent être assez élevées. Enfin, **on note une excellente performance de l'estimation par *shrinkage***, comparativement aux autres méthodes.

Si on s'intéresse au cas de la distance d_3 dont les distributions sont consignées dans la figure 2, on notera que les résultats sont comparables, et que les conclusions qui en découlent sont les mêmes.



Graphique 2: Risque du portefeuille de variance minimale

Les distributions de la distance d_1 sont fournies en annexe B.

Données avec valeurs manquantes


Nous avons choisi de simuler un historique de dix ans ($T = 120$). Puis nous avons remplacé les premières valeurs des trois premiers actifs par des valeurs manquantes. Elles symbolisent le fait que les historiques de rendement ne sont pas toujours connus sur les mêmes périodes historiques pour tous les actifs. Finalement, les historiques retenus sont :

- $T = 48$ pour le premier actif;
- $T = 72$ pour le deuxième actif;
- $T = 84$ pour le troisième actif;
- $T = 120$ pour tous les autres actifs.


La distribution de la distance d_2 est donnée par le graphique 3.

On note que **le meilleur estimateur est maintenant celui qui maximise la vraisemblance**. Certains estimateurs n'utilisent qu'une partie de l'information disponible (*listwise*, *shrinkage*, modèles à facteurs) et sont donc largement pénalisés. L'estimateur *pairwise*, quant à lui, n'est pas robuste car certaines valeurs propres de la matrice de covariance sont proches de 0. L'inversion de cette matrice peut alors conduire à des valeurs totalement aberrantes.

Des résultats similaires sont illustrés par le graphique 4 dans le cas de la distance d_3 .



Graphique 3: Tracking error entre le portefeuille estimé et le portefeuille optimal




Graphique 4: Risque du portefeuille de variance minimale

2.3 Impact d'une erreur d'estimation sur le portefeuille optimal

Les parties précédentes ont permis de comparer les méthodes, les unes par rapport aux autres. Nous souhaitons maintenant, pour une méthodologie donnée (par exemple l'estimation par *shrinkage*), indiquer à quels portefeuilles *optimaux* une erreur d'estimation peut conduire.

Pour cela, nous nous donnons comme précédemment un vecteur de rendements espérés et une matrice de covariance (toujours ceux détaillés en annexe A). Le coefficient d'aversion au risque vaut $\lambda = 2$. Nous indiquons sur le graphique 5 où se situent les différents portefeuilles estimés (un point représente une simulation), ainsi que le portefeuille réellement optimal (indiqué par une croix).



Graphique 5: Impact de la longueur d'historique sur le portefeuille estimé

Évidemment, les portefeuilles estimés se rapprochent du portefeuille optimal lorsque T (longueur d'historique) augmente. Enfin, on remarquera que, lorsque l'historique disponible est faible ($T = 50$ soit environ 4 ans par exemple) le portefeuille estimé peut être relativement « loin » du portefeuille optimal.

Conclusion

Deux méthodes d'estimation de la matrice de covariance sont particulièrement intéressantes.

La première, l'estimation par *shrinkage*, est la plus efficace (au moins au sens d'un critère cohérent avec la gestion d'actifs) lorsque les historiques de rendements ne comportent pas de valeurs manquantes, c'est-à-dire que les historiques de tous les actifs sont connus sur les mêmes périodes.

La deuxième, l'estimation par maximisation de la vraisemblance, permet de gérer au mieux les cas où certains historiques sont relativement courts.

Nous n'avons pas présenté de méthodologie permettant de choisir entre ces deux méthodologies. Cependant, il nous semble, d'après les tests que nous avons effectués, qu'il faut choisir l'estimation par maximum de vraisemblance lorsque l'estimation par *shrinkage* conduit à une perte d'information d'au moins 30% à 40%.

Annexes

A Données utilisées pour les simulations

Les rendements espérés des treize classes d'actifs sont supposés égaux à :

$$\mu = \begin{pmatrix} 7.82\% \\ 4.77\% \\ 4.72\% \\ 5.75\% \\ 4.19\% \\ 8.51\% \\ 9.70\% \\ 5.39\% \\ 10.34\% \\ 4.58\% \\ 5.51\% \\ 4.67\% \\ 4.20\% \end{pmatrix}$$


La volatilité des actifs vaut

$$\sigma = \begin{pmatrix} 18.0\% \\ 6.1\% \\ 5.9\% \\ 11.6\% \\ 2.0\% \\ 22.0\% \\ 26.0\% \\ 15.0\% \\ 46.0\% \\ 4.3\% \\ 9.6\% \\ 5.4\% \\ 3.0\% \end{pmatrix}$$


et la matrice de corrélation est prise égale à :

$$\rho = \begin{pmatrix} 1 & 0.15 & 0.1 & 0.25 & 0.1 & 0.9 & 0.8 & 0.3 & 0.5 & 0.15 & 0.25 & 0.15 & 0 \\ 0.15 & 1 & 0.8 & 0.8 & 0.5 & 0.15 & 0.15 & -0.2 & -0.1 & 0.75 & 0.65 & 0.8 & 0.3 \\ 0.1 & 0.8 & 1 & 0.8 & 0.5 & 0.15 & 0.15 & -0.2 & -0.1 & 0.75 & 0.65 & 0.8 & 0.3 \\ 0.25 & 0.8 & 0.8 & 1 & 0.4 & 0.2 & 0.2 & -0.1 & 0 & 0.75 & 0.85 & 0.8 & 0.3 \\ 0.1 & 0.5 & 0.5 & 0.4 & 1 & 0 & 0 & 0 & 0 & 0.3 & 0.3 & 0.3 & 0.1 \\ 0.9 & 0.15 & 0.15 & 0.2 & 0 & 1 & 0.8 & 0.3 & 0.5 & 0.15 & 0.25 & 0.15 & 0 \\ 0.8 & 0.15 & 0.15 & 0.2 & 0 & 0.8 & 1 & 0.4 & 0.6 & 0.2 & 0.3 & 0.1 & 0 \\ 0.3 & -0.2 & -0.2 & -0.1 & 0 & 0.3 & 0.4 & 1 & 0.4 & -0.2 & -0.1 & -0.2 & -0.1 \\ 0.5 & -0.1 & -0.1 & 0 & 0 & 0.5 & 0.6 & 0.4 & 1 & -0.1 & 0.05 & -0.1 & -0.1 \\ 0.15 & 0.75 & 0.75 & 0.75 & 0.3 & 0.15 & 0.2 & -0.2 & -0.1 & 1 & 0.75 & 0.75 & 0.3 \\ 0.25 & 0.65 & 0.65 & 0.85 & 0.3 & 0.25 & 0.3 & -0.1 & 0.05 & 0.75 & 1 & 0.7 & 0.2 \\ 0.15 & 0.8 & 0.8 & 0.8 & 0.3 & 0.15 & 0.1 & -0.2 & -0.1 & 0.75 & 0.7 & 10.3 & \\ 0 & 0.3 & 0.3 & 0.3 & 0.1 & 0 & 0 & -0.1 & -0.1 & 0.3 & 0.2 & 0.3 & 1 \end{pmatrix}$$

B Graphiques de distribution de l'erreur quadratique



Graphique 6: Erreur quadratique entre la matrice de covariance estimée, et la matrice de covariance réelle (sans données manquantes)



Graphique 7: Erreur quadratique entre la matrice de covariance estimée, et la matrice de covariance réelle(avec données manquantes)

Références

- Bengtsson C. et Holst J., *On Portfolio Selection : Improved Covariance Matrix Estimation for Swedish Asset Returns*, 2002.
- Black F. et Litterman R., *Asset Allocation : Combining Investor Views with Market Equilibrium*, Journal of Fixed Income, 1991
- Black F. et Litterman R., *Global Portfolio Optimization* , Financial Analysts Journal, 1992.
- Bouchaud J.P., Cizeau P., Laloux L. et Potters M., *Noise Dressing of Financial Correlation Matrices*, Physical Review Letters, 1999.
- Boulier J.F., Lardic S. et Taillard G., *Investir longtemps*, Quants 36, Recherche & Innovation, 1999.
- Cox J.C. et Huang C., *Optimum Consumption and Portfolio Policies When Asset Prices Follow a Diffusion Process*, Journal of Economic Theory, 1989.
- Dempster A.P., Laird N.M. et Rubin D.B., *Maximum Likelihood from Incomplete Data via the EM Algorithm* Journal of the Royal Statistical Society 1977.
- Gaussel N., *Selected problems on integration and transmission of information by financial markets*, PhD thesis, 2001.
- Higham N.J., *Computing the nearest correlation matrix - a problem from finance*, Journal of Numerical Analysis, 2002.
- Karatzas I., *Optimization Problems in th Theory of Continuous Trading* , SIAM Journal on Control and Optimization, 1989.
- Ledoit O. et Wolf M. *Improved Estimation of the Covariance Matrix of Stock Returns With an Application to Portfolio Selection*, 2002.
- Ledoit O. et Wolf M. *A Well-Conditioned Estimator For Large-Dimensional Covariance Matrices*, 2003.
- Little T.D., Schnabel K.U. et Baumert J. [Eds.], *Longitudinal and multi-group modeling with missing data*, 2000.
- Markowitz H., *Portfolio Selection : Efficient Diversification of an Investment* , Journal of Finance, 1959.
- Merton R.C., *Continuous Time Finance* , Blackwell Publishers, 1998.
- Samuelson P.A., *Lifetime Portfolio Selection by Dynamic Stochastic Programming*, Review of Economics and Statistics, 1969.
- Sharpe W., *A Simplified Model for Portfolio Analysis*, Management Science, 1963.